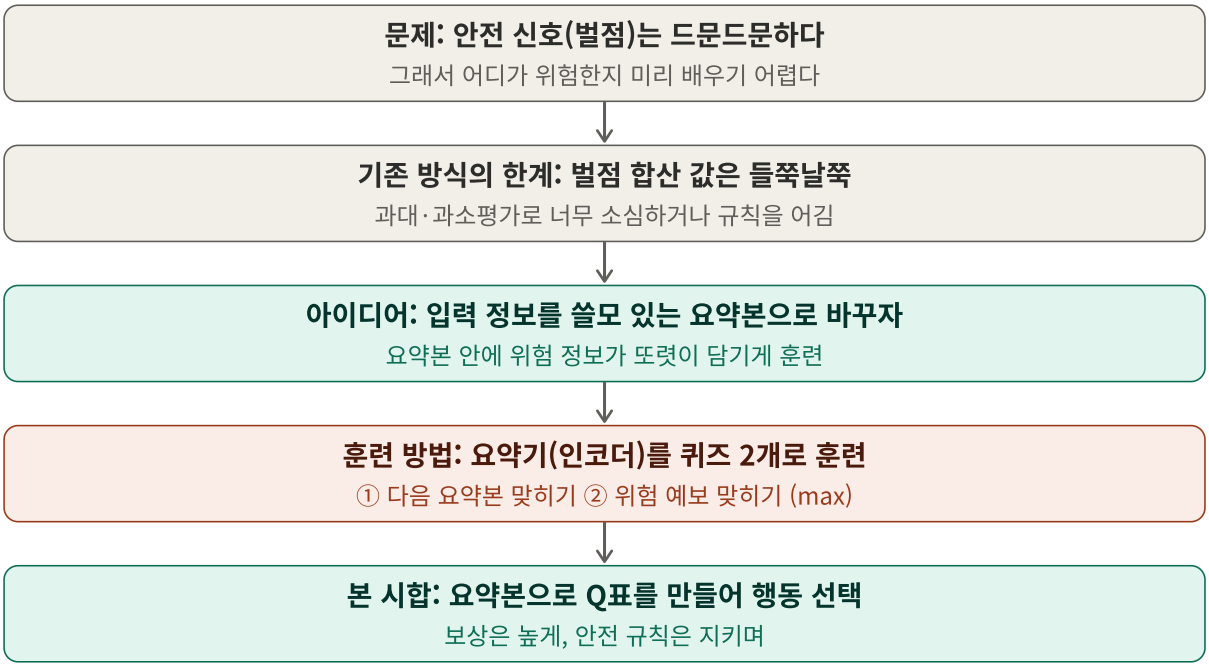
FCSRL 논문 복습 노트

Feasibility Consistent Representation Learning for Safe Reinforcement Learning
Cen, Yao, Liu, Zhao (Carnegie Mellon University) · ICML 2024

한 문장 요약
안전 신호가 드문드문해서 위험을 배우기 어려운 안전 강화학습에서, 로봇이 보는 정보를 **위험 정보가 또렷한 요약본**으로 바꿔 주는 요약기를 **퀴즈 2개**(다음 요약본 맞히기, 위험 예보 맞히기)로 훈련해서 점수와 안전을 둘 다 높이는 방법이에요.

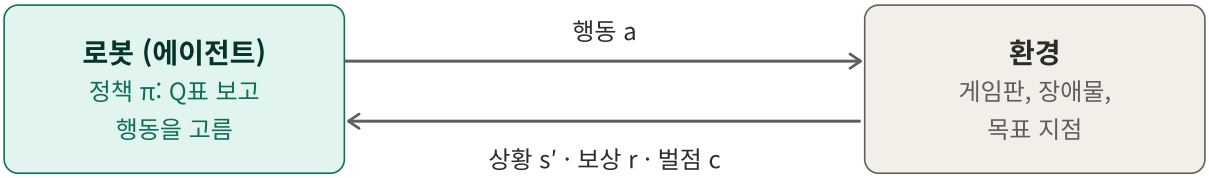
논문 전체 흐름



이 노트 읽는 순서

쪽	내용
2 ~ 3	기초 개념, 이 논문이 풀려는 문제
4 ~ 5	핵심 아이디어(요약본과 퀴즈), 부품 4개 이름표
6 ~ 10	퀴즈 ①, 위험 예보 점수(max), 칸별 확률, 퀴즈 ②, 추측이 정답이 되는 과정
11 ~ 12	전체 훈련 루프, 실험 결과
13 ~ 15	헷갈렸던 질문 모음, 용어 사전(영단어 뜻), 자가 점검

1. 기초 개념 (강아지 훈련으로 이해하기)



개념	쉬운 설명
강화학습 (RL)	강아지(에이전트)가 앉으면 간식(보상)을 받으며 어떤 행동이 이득인지 시행착오로 배워요. 상황(state)을 보고 행동(action)을 고르는 규칙이 **정책(policy)**이에요.
안전 강화학습 (Safe RL)	"소파에 올라가면 안 돼" 같은 **안전 규칙(제약 조건)**이 더해져요. 위험한 행동에는 **벌점(cost)** 1, 아니면 0을 줘요. 목표는 **벌점 합계를 허용치 ε 이하로 지키면서 보상을 최대로** 만드는 거예요.
Q표 (가치 함수)	"이 상황에서 이 행동을 하면 앞으로 점수를 얼마나 받을까?"를 예측하는 계산기(신경망)예요. 이 논문에서는 **보상용과 벌점용이 따로** 있고, 로봇은 둘을 함께 보며 행동을 골라요.
표현 학습 (요약본 만들기)	입력이 복잡할 때 AI가 판단하기 좋은 형태(**요약본, 임베딩 z**)로 바꾸는 법을 배우는 분야를 통틀어 부르는 이름이에요. CURL, SPR, VC 모델, 그리고 FCSRL이 모두 그 한 종류예요.

입력과 출력이란?

입력(input)은 계산기(신경망)가 **받아서 계산하는 재료**, **출력(output)**은 계산해서 **내놓는 결과**예요. 이 노트에서 "요약본을 Q표의 입력으로 넣는다"는 말은 "Q표에 원본 상황 대신 요약본을 재료로 준다"는 뜻이에요.



표현 학습과 강화학습의 관계

둘은 **포함 관계가 아니라 서로 다른 분야**예요. 표현 학습은 "입력을 쓸모 있는 요약본으로 바꾸는 법", 강화학습은 "보상을 받으며 행동을 고르는 법"이에요. 다만 이 논문처럼 **표현 학습으로 만든 요약본을 강화학습의 입력으로 끼워 쓰면** 함께 동작해요.



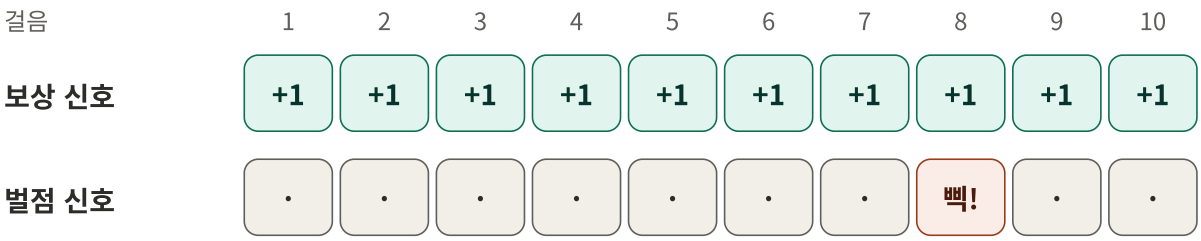
요약본 z가 강화학습의 입력으로 전달

FCSRL의 위치: 새로운 강화학습 알고리즘이 아니라, PPO-Lag나 TD3-Lag 같은 기존 Model-free 안전 강화학습에 **끼워 쓰는 요약기 훈련 방법**이에요. 표현 학습(기존 기술)에 "안전성(Feasibility)을 뽑아내는 목표"를 새로 더한 버전이에요.

강화학습의 진짜 목표: Q표를 채우는 것 자체가 아니라, **Q표를 보고 행동을 골랐을 때 보상이 최대가 되게**(안전 규칙은 지키며) 만드는 거예요. Q표 채우기는 수단이에요. 이 방식은 환경이 어떻게 움직이는지 몰라도 해보면서 배워서 **Model-free**라고 불러요. 그래서 강화학습 본체에는 "다음 상태 예측"이 없어요.

2. 이 논문이 풀려는 문제

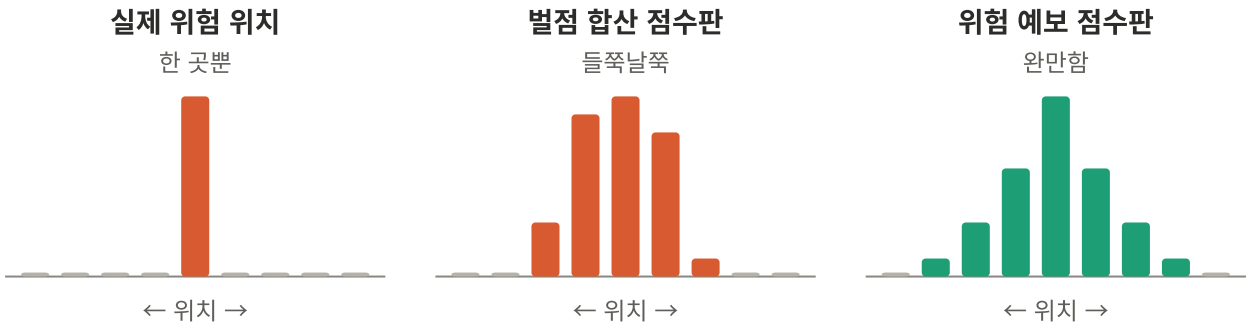
문제 1: 안전 신호는 드문드문하다 (희소, sparse)



보상은 걸음마다 촘촘히, 벌점은 위험한 순간에만 드문드문 옵니다 (희소, sparse)

보상은 걸음마다 오지만 벌점은 위험한 순간에만 와요. 그래서 로봇은 **"지금 이 자리가 위험한 곳인지"를 알아차리고 미리 예측하기**가 어려워요. (위험한 곳에 가도 못 알아차린다기보다, 위험이 가끔만 알려져서 **미리 배우기 어렵다**는 뜻이에요.)

문제 2: 벌점을 합산한 가치 함수는 들쭉날쭉하다 (non-smooth)



※ 숫자는 분위기를 보여주려는 임의의 값이에요. 실제 그림은 논문 Figure 2에 있어요.

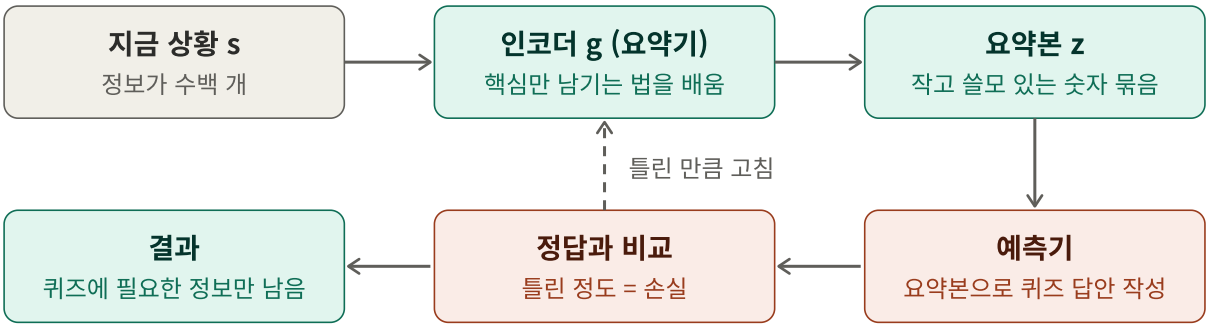
기존 벌점 기반 가치 함수(V^c)는 위험 근처에서 값이 갑자기 튀고 떨어져서 추정에 잡음이 커요. 그러면 두 가지 일이 생겨요.

잘못 읽으면	결과
과대평가	안 위험한데 "엄청 위험해!"라고 읽음 → 겁먹고 **너무 소심한 정책**이 되어 보상이 줄어요.
과소평가	진짜 위험한데 "괜찮아"라고 읽음 → 규칙을 어기고, 그러면 벌점 무게 λ가 커져서 결국 **보상도 줄어요**.

논문이 꼽은 어려움의 두 원인
① 원본 입력이 복잡해서 **한 걸음 단위의 위험 판단** 자체가 어려움 ② 벌점이 희소해서 **장기적인 안전 추정**이 들쭉날쭉해지고 잡음이 큼.
→ 이 논문은 둘 다 **표현 학습**(요약본 만들기)으로 풀려고 해요.

참고: 라그랑주 승수 λ — 규칙을 어길 때 벌점의 무게를 키워 주는 조절 장치예요. 뒤에 나오는 λ_{fea}(위험 예보 손실의 중요도)와 이름이 비슷하지만 **다른 값**이에요.

3. 핵심 아이디어: 퀴즈로 요약기를 훈련한다



"요약"은 자르기가 아니에요

사람은 요약할 때 중요한 게 뭔지 이미 알지만, **AI는 시작할 때 무엇이 중요한지 몰라요.** 그래서 "이 요약본으로 퀴즈를 풀 수 있어야 해"라는 **선별 기준**을 줘요. 퀴즈를 풀려면 필요한 정보만 살아남고 나머지는 버려져요. 퀴즈는 요약본을 만든 뒤 보는 시험이 아니라, **무엇을 남길지 정해 주는 장치**예요.

퀴즈	요약본에 담기는 것
① **다음 요약본 맞히기**	"세상이 어떻게 움직이나" (움직임 정보). 안전과 상관없는 정보도 똑같이 담겨요.
② **위험 예보 맞히기**	"어디가 위험한가" (안전 정보). 위험은 드물어서 ①만 하면 **"별로 안 중요하네" 하고 버려지기 쉬워서**, 따로 못 박아 줘요.

왜 정답을 그냥 주지 않고 퀴즈를 풀게 할까?

- **일반화**: 계산된 정답은 이미 겪은 경험에만 있어요. 처음 보는 상황에선 정답이 없으니, 요약기가 스스로 위험 단서를 뽑는 **푸는 법**을 익혀야 해요.
- **정답 복붙 문제**: 정답을 직접 넣으면 요약본이 정답지가 되어서, 정답이 없는 곳에선 쓸모가 없어요.

정리: 퀴즈 풀기는 전체 과정이 아니라 **요약기를 훈련시키는 한 단계**예요. 훈련이 끝난 요약본은 **Q표와 행동 규칙의 입력**으로 쓰이고, 퀴즈 답안을 쓰는 예측기는 훈련용 부품이에요.

비유: 학생에게 "이 글의 핵심만 노트에 적어"라고 한 뒤, 그 노트만 보고 퀴즈를 풀게 해요. 퀴즈를 맞히려면 노트에 핵심이 들어 있어야 하니까 퀴즈는 **노트를 잘 쓰게 만드는 장치**예요.

4. 부품 4개와 느림보(모멘텀) 인코더

인코더 g (빠른 것)
훈련 대상 (틀린 만큼 고쳐짐)
두 퀴즈의 답안 쪽에서 사용
g(m)이 이걸 천천히 따라감

느림보 인코더 g(m)
직접 훈련 안 함
g를 천천히 따라가는 복사본(EMA)
정답 재료와 Q표 입력을 만듦

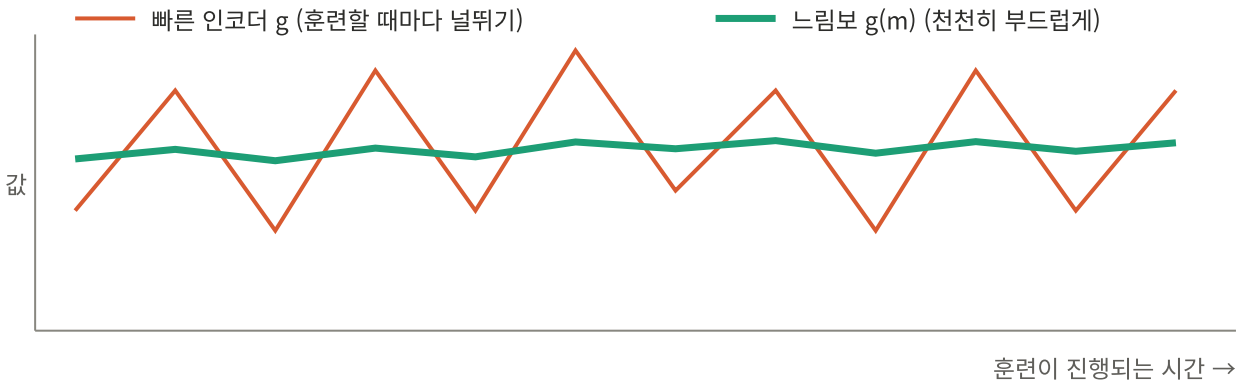
예측기 h
퀴즈 ① 전용 (다음 요약본 추측)
요약기 훈련에만 사용
행동 고를 때는 쓰지 않음

위험 예보 예측기 $\hat{f}$
퀴즈 ② 전용 (복사본 없이 하나)
답안과 비교 대상 재료에 같은 것 사용
행동 고를 때는 쓰지 않음

느림보 복사본이 있는 건 인코더 하나뿐
예측기 h와 $\hat{f}$는 각각 하나씩이고, 느림보 예측기는 없음

이름 정리: "느림보 인코더 = 모멘텀 인코더 = 타깃 인코더 = g(m)"은 **모두 같은 부품**이고, 빠른 인코더 g와는 **다른 부품**이에요.

느림보 인코더는 왜 필요할까?

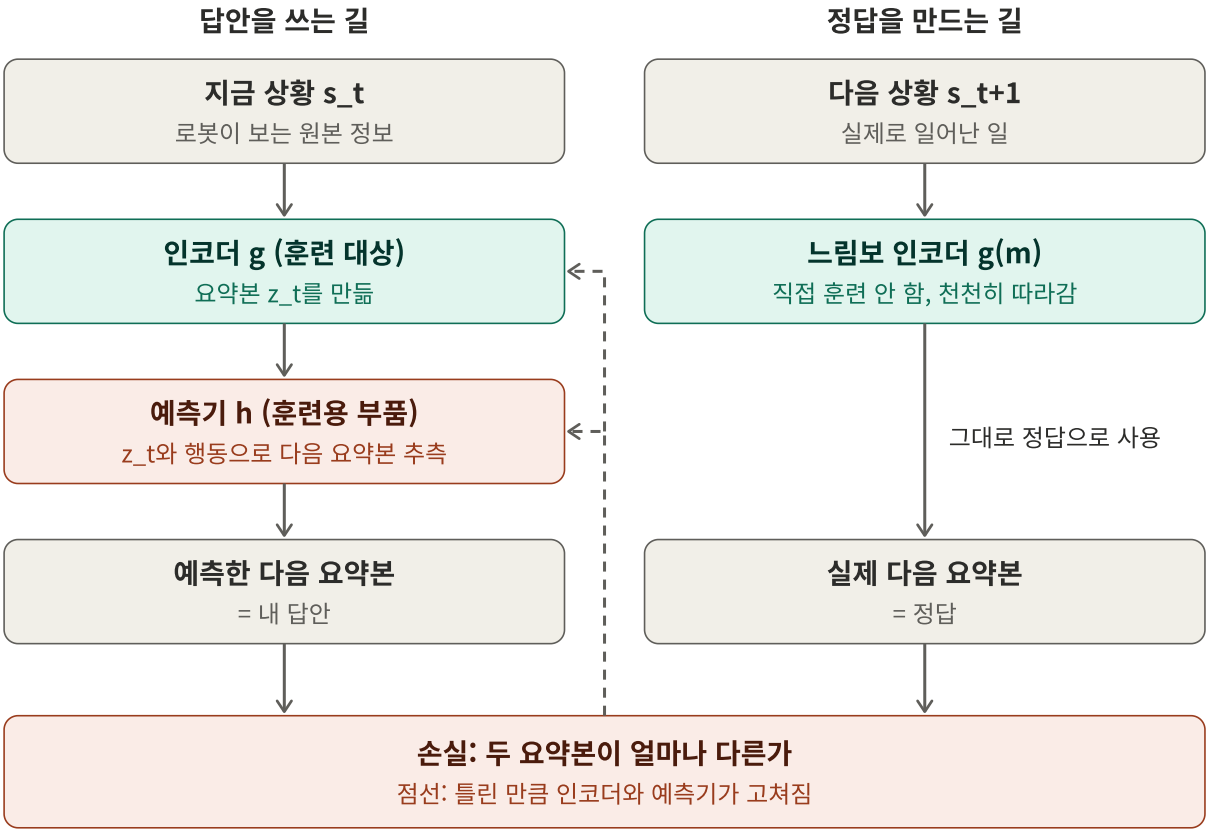


※ 이해를 돕기 위한 예시 그림이에요.

- 비교 대상(정답 쪽)을 만드는 요약기도 같이 마구 바뀌면 **서로를 쫓아다니다가 요약본이 전부 같은 값으로 뭉개지는 문제(표현 붕괴)**가 생길 수 있어요.
- 그래서 정답 쪽은 **느림보 복사본**을 써요. 갱신 방식은 EMA(지수이동평균)로, **자기 값은 대부분 유지하고 빠른 g의 값을 아주 조금만 섞어서** 천천히 바꿔요.
- 비유: 시험 도중 정답지를 계속 고쳐 쓰면 학생이 헷갈려요. **정답지는 천천히만 바뀌어야** 안정적이에요.

5. 퀴즈 ① 다음 요약본 맞히기

Transition Dynamics Consistency (전이 역학 일관성)



$$\ell_{dyn}(\tau) := D_{dyn}(\, z_{t+1}\,,\, z^{(m)}{}_{t+1}\,) \quad (z_t = g(s_t),\ \text{예측}\ z_{t+1} = h(z_t, a_t),\ \text{정답}\ z^{(m)}{}_{t+1} = g^{(m)}(s_{t+1}))$$

- **τ(타우)**는 경험 한 조각(상황 → 행동 → 다음 상황), $\mathbf{D_{dyn}}$은 두 요약본이 얼마나 다른지 재는 자예요 (SimSiam 방식, 코사인 유사도 기반).
- 한 걸음이 아니라 **K걸음 앞까지** 이어서 맞히게 확장할 수 있어요 (논문은 K = 4).
- 이 퀴즈의 정답은 **실제로 일어난 다음 상황에서 측정한 값**이에요. (추측을 섞는 부트스트랩이 아니에요.)
- 손실을 작게 만드는 것(예측을 잘하는 것)은 맞아요. 다만 **예측 정확도 자체가 최종 목표는 아니에요.** 환경을 정밀하게 예측하는 Model-based RL과 달리, 요약본에 움직임의 구조를 담기 위한 **보조 연습**이에요.

비유: 축구 선수의 목표는 시합에서 이기는 거예요. 달리기 기록 단축(손실 줄이기)은 열심히 하지만, 진짜 목표는 기록이 아니라 시합이에요. 다음 요약본 맞히기 연습도 같아요.

예측기 h는 왜 필요? 지금 요약본은 "지금 상황"의 것이라 다음 요약본과 다를 수밖에 없어요. 그래서 **"지금 요약본 + 행동 → 다음 요약본"**을 계산해 주는 작은 장치 h가 필요해요.

6. 위험 예보 점수 (Feasibility Score) — 합산이 아니라 max

$$F^{\pi}(s, a) := E_{\rho\sim\pi}\left[\max_t \gamma^t \cdot c(s_t, a_t) \;\middle|\; s_0 = s, a_0 = a \right]$$

말로 풀면: 지금 상황 s에서 행동 a를 하고, 그 뒤로도 정책 π대로 계속 움직일 때 **앞으로 만나는 벌점 중 가장 큰 값 하나**(가까운 위험일수록 크게 침)를 여러 번 해본 평균이에요.

기호	뜻
π (파이)	정책, 행동을 고르는 규칙
ρ (로) ~ π	정책대로 움직였을 때 나오는 경로(trajectory)들
E (Expectation)	기댓값 = 여러 번 해본 평균
$\max_t$	시간 순서대로 보면서 가장 큰 값 하나만 고름 (합산 X)
γ (감마, discount factor)	먼 미래일수록 값을 깎는 할인율 (논문은 0.99)
$c(s_t, a_t)$	t 시점의 벌점 (위험하면 1, 아니면 0)

합산과 max는 어떻게 다를까? (γ = 1, 8걸음 예시)

걸음	1	2	3	4	5	6	7	8
벌점 기록	0	0	1	0	0	1	0	0
합산(기존)	2	2	2	1	1	1	0	0
max(논문)	1	1	1	1	1	1	0	0

각 걸음에서 "지금부터 끝까지"를 봤을 때의 값이에요 (이미 지난 과거는 보지 않아요).

- **합산**: 남은 위험 개수만큼 2 → 1 → 0으로 계단처럼 바뀌어요.
- **max**: 앞으로 위험이 **한 번이라도 있는지(1) 없는지(0)**만 구분해서 변화가 단순해요.

Proposition 4.1 (직관): 벌점이 0 또는 1이고 γ가 1에 가까우면 **1 − F = "앞으로 계속 안전할 확률"**이에요. 즉 F는 **"앞으로 한 번이라도 위험해질 확률"**처럼 읽을 수 있어서, 안전 정보를 담는 보조 문제로 좋아요.

F(s, a)는 모든 s, a 조합마다 하나씩 있는 값이지만, 전부 계산할 수는 없어서 **모은 경험으로 일부만 계산하고 신경망이 나머지를 예측하도록** 학습해요.

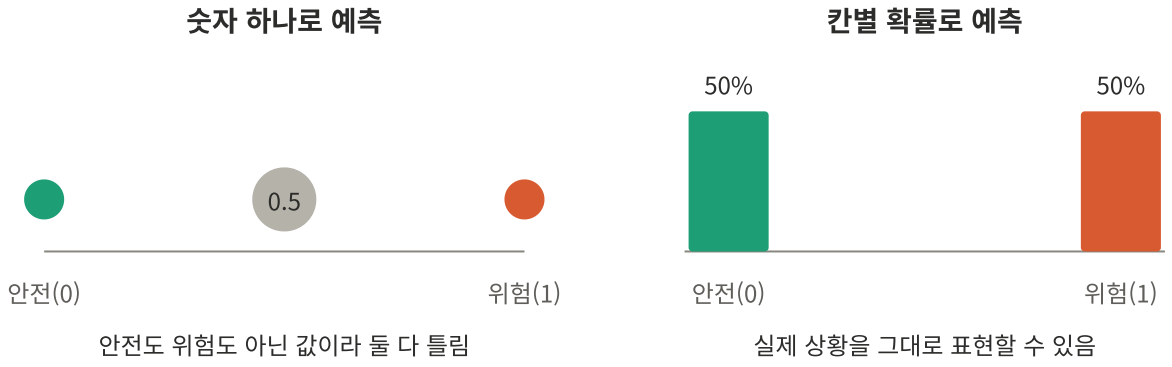
7. 왜 부드러운가, 그리고 칸별 확률로 맞히기

부드러움 (Proposition 4.3)

$$L(f, \rho) := E_{\rho} \mid f(t) - f(t+1) \mid \;\rightarrow\; L(\hat{F}, \rho) \leq L(\hat{V}_c, \rho) \quad \text{(모든 경로 } \rho\text{)}$$

- **L**은 한 걸음마다 값이 얼마나 변하는지의 **평균 변화량**이에요. 작을수록 부드러워요.
- 어떤 경로에서도 **위험 예보 점수 F가 벌점 가치 함수 V_c보다 덜 출렁인다**는 걸 수식으로 증명했어요 (논문 부록 A.2).
- 실험(Figure 2, PointGoal2): V_c의 점수판은 울퉁불퉁하고, F의 점수판은 **장애물 위치에서 솟아오르는 모양**으로 위험 구역과 잘 맞았어요.

숫자 하나가 아니라 칸별 확률로 맞히기 (분포 강화학습, 이산 회귀)



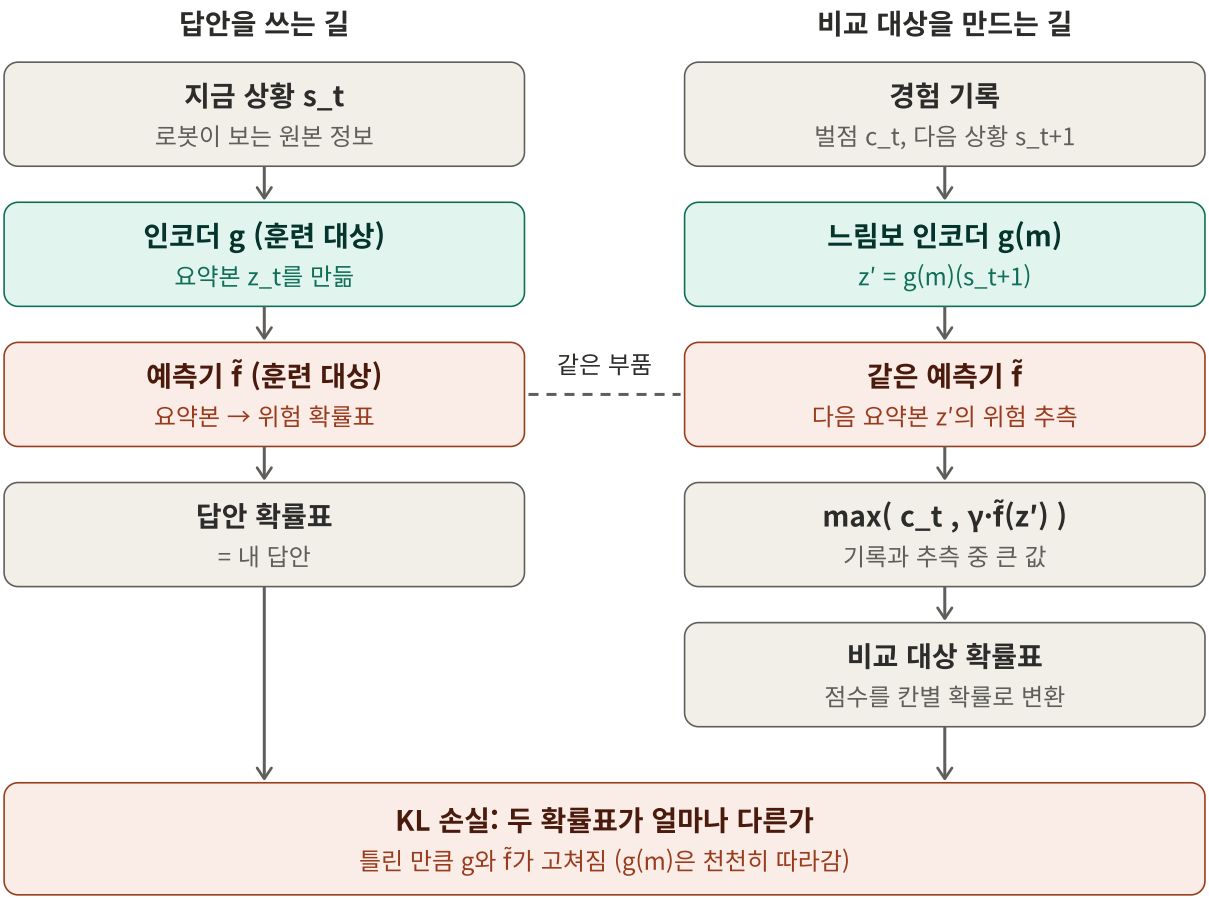
- 위험 예보 퀴즈는 **행동 a 없이 요약본 z만 보고** 맞혀요. 그래서 같은 요약본이라도 **행동에 따라 결과가 갈려요** (행동 A는 안전, 행동 B는 위험).
- 이때 숫자 하나(0.5)로 찍으면 둘 다 틀려요. 그래서 점수 범위를 **여러 칸(논문은 63칸)**으로 나누고 **칸마다 확률**을 예측해서 "안전할 수도, 위험할 수도"를 그대로 표현해요.
- 일기예보에서 "내일 20도"보다 "비 올 확률 60%"가 더 정직한 것과 같아요.

$$\ell_{fea}(\tau) = D_{KL}\left(d_{F(m)}(s_t) \;\|\; d_{\tilde{f}}(z_t) \right)$$

기호	뜻
$d_{F(m)}(s_t)$	비교 대상 위험 점수를 칸별 확률표로 바꾼 것
$d_{\tilde{f}}(z_t)$	요약본 z_t를 보고 예측기 $\tilde{f}$가 낸 **답안 확률표**
D_{KL} (KL 발산)	두 확률표가 얼마나 다른지 재는 자. 같으면 0, 다를수록 커져요.
$\|$ (이중 세로줄)	"앞의 것과 뒤의 것을 비교한다"는 KL의 표기

8. 퀴즈 ② 위험 예보 맞히기

Feasibility Consistency (위험 예보 일관성)



답안: $\tilde{f}(z_t)$ | 비교 대상: $F^{(m)}(s_t) = \max\{ c_t , \gamma \cdot \tilde{f}(z^{(m)}_{t+1}) \}$

- c_t는 실제로 받은 벌점 기록이고, **$\gamma \cdot \tilde{f}(z')$**는 느림보가 만든 다음 요약본 z'를 **같은 예측기 $\tilde{f}$**에 넣어 얻은 "한 걸음 뒤 위험 추측"(에 할인율을 곱한 값)이에요.
- 둘 중 큰 쪽을 고르니까, 지금 이미 위험($c_t = 1$)이면 비교 대상은 무조건 1이고, 아니면 한 걸음 뒤의 위험 추측이 그대로 비교 대상이 돼요.
- "한 걸음 뒤의 위험"은 앞으로 끝까지 가 봐야 아는 값이라 지금은 계산할 수 없어서, **자기 모델의 추측을 재료로** 써요. 그래서 비교 대상을 만드는 길에도 인코더와 예측기가 나와요.

주의: 이 비교 대상은 "순수한 정답"이 아니에요. 진짜 벌점 기록(c_t)과 한 걸음 뒤 추측을 섞은 **더 믿을 만한 추측**이에요. 다음 쪽에서 왜 이게 통하는지 그림으로 볼게요.

예측기가 필요한 이유: 정답은 점수(숫자)인데 요약본은 숫자 묶음이라 모양이 달라서 바로 비교할 수 없어요. 요약본을 점수(확률표)로 **번역해 주는 훈련용 부품**이 예측기예요.

9. 추측이 정답이 되는 과정 (부트스트랩)

	멀리	중간	가까이	위험 구역 (c=1)
훈련 1회차	?	?	?	1
훈련 2회차	?	?	0.9	1
훈련 3회차	?	0.81	0.9	1
훈련 4회차	0.73	0.81	0.9	1

? = 아직 모름 (0 근처) 숫자 = 위험 예보 점수 (γ = 0.9, 복도를 계속 앞으로 간다고 가정한 예시)

- **훈련 1회차**: 위험 구역은 c = 1이라 비교 대상이 추측과 상관없이 **진짜 1**이에요. 예측기는 "여기는 1"을 배워요.
- **훈련 2회차**: 그 한 칸 앞(가까이)의 비교 대상은 "다음 칸 추측 × γ"인데, 다음 칸을 이미 1로 배웠으니 **높은 값**이 나와요.
- 이렇게 **진짜 정보가 위험 지점에서 시작해 한 걸음씩 뒤로 퍼져** 가요. 마라톤에서 "남은 시간 예측"을 배울 때, 결승선 기록이 앞쪽 지점들로 퍼지는 것과 같아요.

CNN 분류와 뭐가 다를까? 일반 분류의 정답(라벨)은 사람이 미리 만든 외부 값이에요. 반면 "앞으로의 위험"은 미리 알 수 없어서 **자기 추측을 재료로 정답을 만들어요.** 강화학습에서 아주 흔한 방식(Bellman 식)이에요.

퀴즈 ①과 ② 비교표

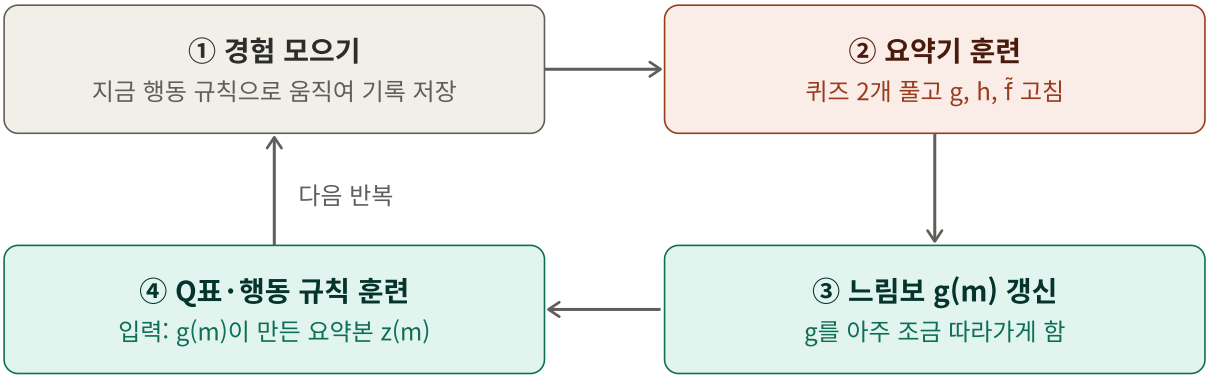
	퀴즈 ① 다음 요약본 맞히기	퀴즈 ② 위험 예보 맞히기
내 답안	$h(\, g(s_t), \text{행동}\,)$	$\tilde{f}(\, g(s_t)\,)$ (행동 없음)
비교 대상	$g^{(m)}(\, s_{t+1}\,)$ (측정값)	$\max(\, c_t, \gamma \cdot \tilde{f}(z')\,)$ (기록 + 추측)
손실	두 요약본의 차이	두 확률표의 KL 차이
고쳐지는 것	인코더 g + 예측기 h	인코더 g + 예측기 $\tilde{f}$
예측기	h (비교 대상 쪽엔 안 나옴)	$\tilde{f}$ (답안과 비교 대상 재료에 **같은 것**)

두 퀴즈의 역할 차이: ①은 요약본에 "세상이 어떻게 움직이나"를 담고, ②는 "어디가 위험한가"를 담아요. 둘은 서로 돕기도 해요. 위험에 닿을지는 앞으로 어떻게 움직일지에 달려 있어서, 움직임을 아는 요약본이 위험도 더 잘 맞히기 때문이에요.

10. 전체 훈련 루프

$$L_\theta = E_{\tau\sim D}\left[\, \ell_{dyn}(\tau) + \lambda_{fea} \cdot \ell_{fea}(\tau) \,\right] \quad (\lambda_{fea} = 2)$$

두 퀴즈의 틀린 정도를 합친 **총점(목적함수)**이에요. 위험 예보 쪽에 2를 곱해 **안전 퀴즈를 두 배 중요하게** 반영해요. θ(세타)는 인코더와 예측기 안의 조절 숫자들 전체이고, D는 모아 둔 경험 저장고(replay buffer)예요. 이 L이 작아지도록 요약기를 훈련해요(최적화).



왜 요약기 훈련과 Q표 훈련을 번갈아 계속할까?

- 로봇은 처음에 **출발점 근처 경험**밖에 없어서, 그것만으로 요약기를 완성해 고정하면 새로 가는 곳은 요약하지 못해요.
- 행동 규칙이 좋아져서 장애물 근처 같은 **새로운 상황**을 만나야 요약기가 위험 정보를 배울 수 있어요. 그래서 요약기 g도 훈련 내내 계속 바뀌어요.

그런데 Q표에는 왜 빠른 g가 아니라 느림보 g(m)의 요약본을 넣을까?

- g는 훈련 때마다 조절 숫자가 바뀌어서 **같은 상황도 어제와 오늘 다른 요약본**이 돼요. 그러면 Q표가 어제 배운 내용이 쓸모없어져요 (논문은 입력에 큰 잡음이 생긴다고 설명해요).
- g(m)은 천천히만 바뀌어서 **같은 상황이 늘 비슷한 요약본**으로 들어와요. 그래서 Q표와 행동 규칙이 안정적으로 배워요.

Q표에 들어가는 것: 요약본 z(m)과 행동을 신경망에 넣으면 "앞으로 받을 점수"가 나와요(보상용·벌점용 둘). 행동 규칙도 요약본을 받아 행동을 내놓는 신경망이에요. **위치·속도 같은 숫자 입력(vector-state) 과제**에서는 원본 상태와 요약본을 **붙여서** 넣어요 (SALE 방식).

정리: 예측기 h, f̃는 **요약기를 훈련할 때만** 쓰이고, 행동을 고르는 본 시합에는 쓰이지 않아요.

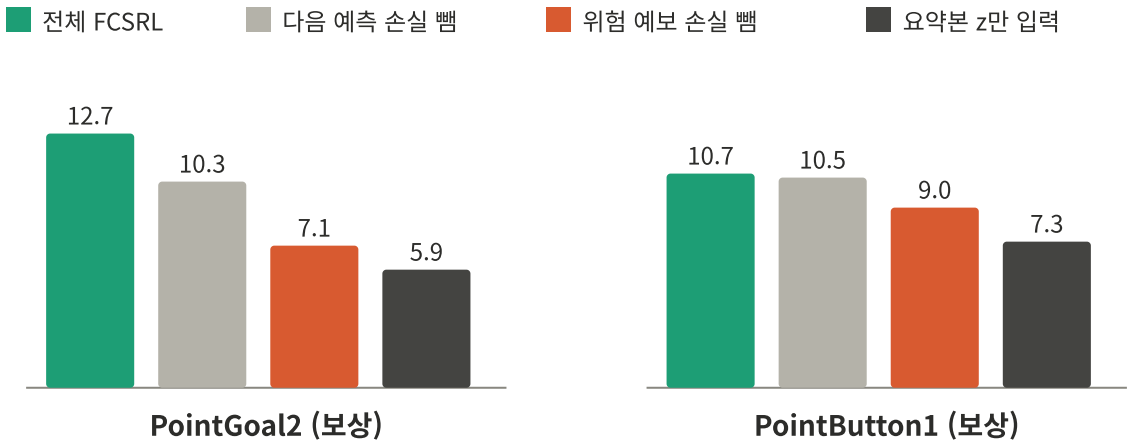
11. 실험과 결과

설정	내용
과제	Safety-Gymnasium의 로봇 제어 과제: **숫자 입력(vector-state) 6개, 이미지 입력 3개**
기반 알고리즘	PPO-Lag(on-policy), TD3-Lag(off-policy). 벌점 허용치는 TD3-Lag ε = 10, PPO-Lag ε = 25. 200만 걸음, 5개 시드
비교 대상	숫자 입력: Raw state, Forward raw/latent, Inverse, TCL, SALE, VC · 이미지 입력: CURL, SPR, VC
구조	모든 방법이 같은 신경망 구조 (예측기·인코더는 2층 MLP, 이미지는 4층 CNN), 요약본 차원 64(숫자)/128(이미지)

결과 요약

- **숫자 입력**: FCSRL이 대부분의 과제에서 가장 좋았어요. 원본 상태만 쓴 TD3-Lag은 안전 규칙을 지키지 못했어요.
- **이미지 입력**: **CURL**은 한 장면만 요약해서 지나치게 소극적(보상·벌점 모두 0 근처)이었고, **SPR**은 PointButton1·PointGoal2에서 규칙을 못 지켜 λ가 커지며 보상이 줄었어요. VC와 FCSRL은 둘 다 좋았고 FCSRL이 더 좋았어요.
- **규칙이 빡빡할수록 차이가 커져요** (허용치 ε = 5, 10, 20, 30, 40 실험). 허용치가 30 이상으로 느슨하면 SALE, VC와 비슷해요. 허용치가 20 이상이면 제한 없이 학습한 정책도 이미 규칙을 지켜서 벌점이 허용치까지 차지 않아요.
- CPO, PPO-Lag, FOCOPS, CVPO 같은 다른 안전 강화학습과 비교해도 대부분의 과제에서 **규칙을 지키면서 가장 높은 보상**을 얻었어요.

부품을 하나씩 빼 보니 (Ablation, ε = 10, 벌점은 모두 약 10으로 규칙은 지킴)



- **위험 예보 손실을 빼면 크게 떨어져요** (12.7 → 7.1, 10.7 → 9.0). 다음 예측 손실을 빼면 조금만 떨어져요. 이 논문에서는 위험 예보가 특히 중요했어요.
- **요약본 z만** 넣으면 크게 떨어져요. 숫자 입력 과제에서는 원본 상태에 보상과 관련된 정보(예: 목표까지 거리)가 더 들어 있기 때문이에요.
- 표현 품질 비교: 요약본으로 벌점 가치를 맞히는 오차는 FCSRL 17.6, VC 17.3으로 비슷했지만, **위험 예보 점수 오차는 FCSRL 0.139, VC 0.217**로 위험 예보가 더 쉽게 배워졌어요.

향후 방향: 위험 예보 점수를 정책 학습의 보조 신호로 써서 "모든 상황에서 안전"(state-wise safety)을 달성하는 것.

12. 헷갈렸던 질문 모음 (FAQ)

Q1. 표현 학습이 새로운 거야, 아니면 표현 학습에 새로운 게 더해진 거야?
표현 학습 자체는 예전부터 있던 기술이에요. 이 논문은 거기에 "안전성(Feasibility)을 뽑아내는 목표"를 새로 더했어요.

Q2. 목적함수는 학습하는 거야, 아니면 학습할 때 가지는 거야?
학습하는 게 아니라, 학습할 때 쓰는 채점표예요. AI는 이 점수(손실)가 좋아지도록 스스로 고쳐 나가요.

Q3. 강화학습엔 다음 상태 예측이 없다는데, 여기선 왜 해?
강화학습 본체(Model-free)에는 없어요. 이 논문은 요약기를 똑똑하게 만들려고 요약본 안에서만 "다음 요약본 맞히기"를 보조 연습으로 붙였어요. 손실을 줄이는 건 맞지만 예측 정확도 자체가 최종 목표는 아니에요.

Q4. 인코더 g, 느림보 인코더, g(m)은 다 다른 거야?
"느림보 인코더"와 "g(m)"은 같은 부품이고, 빠른 인코더 g만 달라요. 느림보 복사본이 있는 부품은 인코더 하나뿐이에요.

Q5. 위험 예보 예측기와 "느림보 예측기"는 별개야?
느림보 예측기는 따로 없어요. 같은 예측기 $\tilde{f}$ 하나에 다른 입력(지금 요약본 z_t, 느림보가 만든 다음 요약본 z')을 넣는 거예요.

Q6. 예측기는 왜 필요해? 요약본끼리 바로 비교하면 안 돼?
퀴즈 ①은 "지금 요약본 + 행동 → 다음 요약본"을 계산해 줄 장치(h)가 필요해요. 퀴즈 ②는 요약본(숫자 묶음)과 점수(확률표)의 모양이 달라서 번역해 줄 $\tilde{f}$가 꼭 필요해요.

Q7. 정답을 그냥 주면 안 돼? 왜 퀴즈를 풀어?
처음 보는 상황에는 정답이 없어서 푸는 법(위험 단서를 뽑는 법)을 익혀야 일반화돼요. 또 정답을 넣으면 요약본이 정답지가 돼요.

Q8. "정답"과 비교하는 게 아니라 추측과 비교하는 거야?
퀴즈 ②는 그래요. 비교 대상은 진짜 벌점 기록 + 한 걸음 뒤 추측을 섞은 "더 믿을 만한 추측"이고(부트스트랩), 퀴즈 ①은 측정값이 정답이에요.

Q9. 요약본은 Q표와 별개야?
아니에요. 요약본(정확히는 느림보 g(m)이 만든 z(m))이 Q표와 행동 규칙의 입력으로 들어가요.

Q10. 표현 학습과 강화학습은 별개야? 포함 관계야?
포함 관계가 아니라 서로 다른 분야예요. 표현 학습으로 만든 요약본을 강화학습의 입력으로 끼워 쓰는 "함께 쓰이는 관계"예요.

Q11. "입력"이 뭐야?
계산기(신경망)가 받아서 계산하는 재료예요. 예를 들어 Q표는 "요약본 + 행동"을 입력으로 받아 "앞으로 받을 점수"를 출력으로 내놓아요.

Q12. 강화학습은 거의 다 표현 학습을 써?
아니에요. 이미지처럼 입력이 큰 경우는 사실상 필수지만, 숫자 몇십 개짜리 입력은 원본을 그대로 넣어도 돼요. 다만 요약본이 성능을 올려 주기도 해요.

13. 용어 사전 (한글 · 영단어 · 뜻)

한글	English	뜻
강화학습	Reinforcement Learning (RL)	보상을 받으며 시행착오로 배우는 학습
안전 강화학습	Safe RL	안전 규칙을 지키며 하는 강화학습
에이전트	Agent	학습하는 AI·로봇
상태 / 행동	State (s) / Action (a)	지금 놓인 상황 / 로봇이 하는 동작
입력 / 출력	Input / Output	계산기(신경망)가 받는 재료 / 내놓는 결과
보상	Reward (r)	잘했을 때 받는 점수
비용(벌점)	Cost (c)	위험할 때 받는 벌점 (1 또는 0)
정책	Policy (π)	상황별로 행동을 고르는 규칙
Q표 (가치 함수)	Q / Value function	앞으로 받을 점수를 예측하는 계산기
제약 조건	Constraint	어기면 안 되는 규칙
희소	Sparse	드문드문한
부드러운	Smooth	갑자기 튀지 않고 서서히 변하는
표현 학습	Representation learning	입력을 쓸모 있는 형태로 바꾸는 법을 배움
임베딩 (요약본)	Embedding (z)	압축된 숫자 묶음
인코더	Encoder (g)	원본을 요약본으로 바꾸는 부품
모멘텀 인코더	Momentum encoder g(m)	인코더를 천천히 따라가는 복사본
지수이동평균	EMA (Exponential Moving Average)	자기 값 대부분 유지, 새 값 조금 섞어 천천히 갱신
표현 붕괴	Representation collapse	요약본이 전부 같은 값으로 뭉개지는 문제
예측기	Predictor / Head (h, f̃)	요약본을 비교 대상과 같은 모양으로 번역하는 훈련용 부품
손실	Loss (ℓ)	틀린 정도 (작을수록 좋음)
목적함수	Objective function	학습의 채점표 (총 손실)
최적화	Optimization	손실이 작아지도록 조절 숫자를 계속 고침
전이 역학	Transition dynamics	상황이 다음 상황으로 바뀌는 규칙
위험 예보 점수	Feasibility score (F)	앞으로 만나는 가장 심한 위험 (max)
할인율	Discount factor (γ)	먼 미래일수록 값을 깎는 장치
기댓값	Expectation (E)	여러 번 해본 평균
분포 / 이산 회귀	Distribution / Discrete regression	값의 퍼짐 / 숫자를 칸으로 나눠 칸별 확률로 맞히기
KL 발산	KL divergence	두 확률표가 얼마나 다른지 재는 자
부트스트랩	Bootstrapping	자기 추측을 정답의 재료로 쓰기
경험 저장고	Replay buffer (D)	모아 둔 경험을 담아 두는 곳
라그랑주 승수	Lagrangian multiplier (λ)	규칙을 어길 때 벌점 무게를 조절하는 장치 (λ_fea와 다름)
Model-free	Model-free RL	환경이 어떻게 움직이는지 모른 채 해보며 배우는 방식

14. 자가 점검 (먼저 답해 보고 아래 정답을 확인하세요)

Q1. 이 논문이 풀려는 문제는?

Q2. 요약기를 훈련하는 퀴즈 2개는?

Q3. 위험 예보 점수는 벌점 합산과 무엇이 다른가?

Q4. 퀴즈 ②의 비교 대상 식은?

Q5. 예측기가 필요한 이유는?

Q6. 느림보 복사본이 있는 부품은?

Q7. Q표에 g(m)의 요약본을 넣는 이유는?

Q8. 위험 예보를 숫자 하나가 아니라 칸별 확률로 맞히는 이유는?

Q9. 안전 허용치가 빡빡할수록 결과는?

Q10. 위험 예보 손실과 다음 예측 손실 중 이 논문에서 더 중요했던 것은?

정답

A1. 안전 신호(벌점)가 희소하고 벌점 가치 함수가 들쭉날쭉해서 위험을 배우고 예측하기 어렵다.

A2. ① 다음 요약본 맞히기 ② 위험 예보 점수 맞히기.

A3. 합산하지 않고 앞으로의 벌점 중 최댓값(max) 하나만 봐서 더 부드럽다.

A4. max(c_t , γ·f̃(z′)): 실제 벌점 기록과 한 걸음 뒤 위험 추측 중 큰 값.

A5. 요약본을 비교 대상과 같은 모양(다음 요약본, 위험 확률표)으로 번역해 비교하려고. 훈련용 부품이다.

A6. 인코더 하나뿐. 예측기 h와 f̃는 각각 하나씩이다.

A7. g는 훈련 때마다 바뀌어 같은 상황도 다른 요약본이 되지만, g(m)은 천천히 바뀌어 입력이 안정적이다.

A8. 행동 없이 요약본만 보고 맞히면 같은 요약본도 행동에 따라 결과가 갈려서, 분포로 표현해야 덜 틀린다.

A9. FCSRL과 다른 방법의 차이가 더 커진다. 느슨하면(30 이상) SALE, VC와 비슷하다.

A10. 위험 예보 손실. 빼면 보상이 크게 떨어졌다(12.7 → 7.1).